

Clasificacion de objetos mediante algebra lineal: estudio comparativo de tres representaciones de características bajo un clasificador de minimos cuadrados

Jhonnatan

Facultad de Ingenieria

Universidad Cooperativa de Colombia

Algebra Lineal

Nombre del docente

Fecha de entrega

Clasificacion de objetos mediante algebra lineal: estudio comparativo de tres representaciones de características bajo un clasificador de minimos cuadrados

**Clasificación de objetos mediante álgebra lineal: estudio
comparativo de tres representaciones de características bajo un
clasificador de mínimos cuadrados**

Jhonnatan

Trabajo presentado como requisito para la asignatura de Álgebra Lineal

Docente

Nombre del docente

Universidad Cooperativa de Colombia

Facultad de Ingeniería

Ingeniería de Sistemas

Villavicencio, Meta

2026

esumen pendiente de redaccion.

Abstract

Keywords: linear algebra, object classification, principal component analysis, least squares, singular value decomposition, computer vision.

Introduccion

Objetivos

Objetivo general

Desarrollar un sistema de clasificacion de objetos por tamano, color, forma e identidad, implementado mediante operaciones de algebra lineal, que permita evaluar comparativamente el aporte de tres representaciones de características distintas bajo un mismo clasificador de minimos cuadrados regularizado.

Objetivos especificos

1. Implementar tres extractores de características —descriptores geometricos y cromaticos, proyeccion sobre eigen-objetos mediante descomposicion en valores singulares, y representaciones de una red convolucional preentrenada— empleando unicamente operaciones matriciales programadas sobre NumPy.
2. Construir un clasificador multiclase de minimos cuadrados con regularizacion de Tikhonov, verificando su equivalencia numerica con una implementacion de referencia y caracterizando el efecto del parametro de regularizacion sobre el numero de condicion de la matriz normal.
3. Evaluar el desempeno comparativo de las tres representaciones mediante un estudio de ablacion con validacion cruzada, cuantificando la contribucion de la representacion frente a la del clasificador en la exactitud final del sistema.

Marco teorico

La imagen como objeto algebraico

Una imagen digital en color es un tensor $I \in \mathbb{R}^{H \times W \times 3}$.

Transformaciones lineales de color

La conversion de RGB a YCbCr, en la recomendacion ITU-R BT.601, es una transformacion afin cuya parte lineal es una matriz de 3×3 :

$$\begin{bmatrix} Y \\ C_b \\ C_r \end{bmatrix} = \begin{bmatrix} 0,2990 & 0,5870 & 0,1140 \\ -0,1687 & -0,3313 & 0,5000 \\ 0,5000 & -0,4187 & -0,0813 \end{bmatrix} \begin{bmatrix} R \\ G \\ B \end{bmatrix} + \begin{bmatrix} 0 \\ 128 \\ 128 \end{bmatrix}. \quad (1)$$

La conversion de RGB a HSV, en cambio, *no* es lineal: el tono y la saturacion se definen a partir de $\max(R, G, B)$, $\min(R, G, B)$ y cocientes entre esas cantidades, operaciones que no admiten representacion matricial. Esa es la razon por la que la segmentacion de este trabajo opera en YCbCr.

Momentos y matriz de inercia

Con los momentos centrales de segundo orden de la mascara binaria se construye

$$M = \frac{1}{\mu_{00}} \begin{bmatrix} \mu_{20} & \mu_{11} \\ \mu_{11} & \mu_{02} \end{bmatrix}, \quad (2)$$

matriz simetrica y semidefinida positiva cuyos autovectores son las direcciones principales del objeto y cuyos autovalores miden la dispersion a lo largo de esas direcciones.

Descomposicion en valores singulares y eigen-objetos

Sea $A \in \mathbb{R}^{m \times d}$ la matriz de imagenes centradas. Su descomposicion en valores singulares $A = U\Sigma V^T$ entrega en las columnas de V los autovectores de la matriz de covarianza $C = A^T A / (m - 1)$. Cuando $m \ll d$ se aplica la identidad de Turk y Pentland (1991): si $AA^T u = \mu u$, entonces

$$A^T A (A^T u) = \mu (A^T u), \quad (3)$$

de modo que $v = A^T u / \|A^T u\|$ es autovector de la matriz grande sin necesidad de construirla.

Minimos cuadrados regularizados

El clasificador resuelve

$$\min_W \|XW - Y\|_F^2 + \lambda \|W\|_F^2, \quad W = (X^T X + \lambda I)^{-1} X^T Y, \quad (4)$$

que con $\lambda = 0$ coincide con $W = X^+ Y$, donde X^+ es la pseudoinversa de Moore-Penrose (Boyd & Vandenberghe, 2018).

Numero de condicion y regularizacion

$$\text{cond}_2(X^T X + \lambda I) = \frac{\sigma_{\max} + \lambda}{\sigma_{\min} + \lambda} \quad (5)$$

decrece monotonamente con λ : la regularizacion desplaza todo el espectro y estabiliza la solucion a costa de sesgo.

Cuadro 1*Conceptos de algebra lineal y su punto de aplicacion en el sistema*


Concepto	Donde se aplica
Matrices y tensores	Imagen como $I \in \mathbb{R}^{H \times W \times 3}$
Producto matriz-vector	Conversion RGB a YCbCr y RGB a gris
Autovalores y autovectores	Matriz de inercia 2×2 , ejes principales
Matriz de covarianza	Estandarizacion y analisis de componentes principales
Descomposicion en valores singulares	Eigen-objetos, reduccion de 4096 a k
Relacion entre $A^T A$ y AA^T	Truco de Turk-Pentland para $m \ll n$
Espacios y subespacios vectoriales	Espacio de caracteristicas, subespacio propio
Proyeccion ortogonal	Representacion en el subespacio de eigen-objetos
Minimos cuadrados	Entrenamiento del clasificador
Pseudoinversa de Moore-Penrose	Solucion cerrada $W = X^+ Y$
Rango e independencia lineal	Deteccion de caracteristicas redundantes
Numero de condicion	Diagnostico de $X^T X$ mal condicionada
Regularizacion de Tikhonov	Estabilizacion mediante $+\lambda I$
Norma euclidiana	Baseline k-NN, distancia en el espacio propio
Hiperplanos separadores	Frontera de decision del clasificador lineal

Cuadro 2*Exactitud por representacion bajo validacion cruzada*

Via	Representacion	M exactitud	DE	M macro-F1
A	Fisicas	0.841	0.015	0.841
B	Eigen	0.900	0.011	0.899
C	CNN	0.998	0.002	0.998

Figura 1

Exactitud por representacion bajo validacion cruzada

**Figura 2**

Exactitud y varianza explicada en funcion de k






Figura 3*Exactitud y numero de condicion en funcion de λ* **Cuadro 3***Comparacion contra los baselines*

Baseline	Via	Exactitud
aleatorio	-	0.100
knn_k5	A	0.927
minimos_cuadrados	A	0.821
knn_k5	B	0.976
minimos_cuadrados	B	0.872
knn_k5	C	0.997
minimos_cuadrados	C	0.997
mobilenetv3_cabeza_original	C	0.612

Figura 4

Primeros dieciseis eigen-objetos



Maapeo de conceptos

Metodologia

Datos

Segmentacion y normalizacion

Representaciones evaluadas

Clasificador

Protocolo experimental

Implementacion

Resultados

Comparacion entre representaciones

Efecto del numero de componentes

Efecto de la regularizacion

Comparacion contra los baselines

Figura 5

Proyeccion sobre las dos primeras componentes principales





Figura 6


Matriz de confusion de la via A



Matriz de confusion de la via B



Matriz de confusion de la via C



mientras no existan mediciones de masa.

- Ajuste fino del extractor sobre imagenes del dominio propio, para cerrar la brecha observada entre dataset y camara.
- Banda transportadora fisica, con disparo por fotocelda en lugar del disparador de estabilidad por software.
- Comparacion contra una maquina de vectores de soporte con nucleo, para medir cuanto aporta la no linealidad situada en el clasificador y no en la representacion.

Referencias

- Boyd, S., & Vandenberghe, L. (2018). *Introduction to applied linear algebra: Vectors, matrices, and least squares*. Cambridge University Press.
- Turk, M., & Pentland, A. (1991). Eigenfaces for recognition. *Journal of Cognitive Neuroscience*, 3(1), 71-86.